

Chap.2. Grammaires et Classifications des Langages.

Grammaire :

Une grammaire est un quadruplet $G = (T, N, S, P)$ où :

- **T** est un ensemble non vide de terminaux (l'alphabet sur lequel est défini le langage). Les symboles de **T** sont désignés par les lettres minuscules de l'alphabet Latin (a, b, c,..).
- **N** est un ensemble de non-terminaux tel que $T \cap N = \emptyset$, ce sont des symboles intermédiaires pour produire de nouveaux objets (c'est les symboles qu'il faut encore définir). Ils sont désignés par les lettres majuscules de l'alphabet Latin.
- **S** ∈ **N** est appelé axiome
- **P** est un ensemble de règles de productions ou de réécritures.
Chaque règle est de la forme $\alpha \rightarrow \beta$ avec $\alpha \in (T \cup N)^* N (T \cup N)^*$
(α contient au moins un non-terminal) et $\beta \in (T \cup N)^*$.

P est un ensemble de règles de productions ou de réécritures.
Chaque règle est de la forme $\alpha \rightarrow \beta$ avec $\alpha \in (T \cup N)^* N (T \cup N)^*$
(α contient au moins un non-terminal) et $\beta \in (T \cup N)^*$.

Une règle de production $\alpha \rightarrow \beta$ précise que la séquence de symboles α peut être remplacée par la séquence de symboles β .

α est appelé **membre gauche** et β **membre droit**.

Exemple $G = (T, N, S, P)$

$T = \{a\}$

$N = \{S\}$

$P = \{S \rightarrow aS, S \rightarrow \varepsilon\}$

$P = \{S \rightarrow aS, S \rightarrow \varepsilon\}$

Intuitivement, cette grammaire permet de générer les mots $\varepsilon, a, a^2, a^3, \dots$
C'est le langage $L(G) = \{a^n / n \geq 0\}$.

Notations

Plusieurs règles ayant même membre gauche seront notées en écrivant à droite du symbole $\rightarrow$ les différents membres droits séparés par /.

Exemple

$A \rightarrow aB$

$A \rightarrow bAa$

$A \rightarrow a$

On notera $A \rightarrow aB / bAa / a$

Définition (Dérivation directe)

Soit $G=(T, N, S, P)$ une grammaire. Un mot $m_1 \in (T \cup N)^+$ dérive (ou produit) directement un mot $m_2 \in (T \cup N)^*$ si et seulement si il existe une production $\alpha \rightarrow \beta$ dans P telle que : $m_1 = u\alpha v$ et $m_2 = u\beta v$ avec $u, v \in (T \cup N)^*$. On écrit alors $m_1 \rightarrow m_2$.

Exemple Soit $G = (\{0, 1\}, \{S\}, S, \{S \rightarrow 0S1 / \varepsilon\})$

$0S1$ dérive directement de S : $S \rightarrow 0S1$

ε dérive directement de S : $S \rightarrow \varepsilon$

Définition (Dérivation indirecte)

Soit $G = (T, N, S, P)$ une grammaire. Un mot $w_1 \in (T \cup N)^+$ dérive indirectement (ou simplement dérive) un mot $w_2 \in (T \cup N)^*$ si et seulement si w_2 peut être obtenu par une succession de zéro, une ou plusieurs dérivations directes à partir de w_1 . On écrit alors $w_1 \rightarrow^* w_2$

Définition (Langage engendré par une grammaire)

Le langage engendré par une grammaire, noté $L(G)$, est exactement l'ensemble des mots appartenant à T^* générés (directement ou indirectement) à partir de l'axiome.

$$L(G) = \{w / S \rightarrow^* w \text{ et } w \in T^*\}$$

Le langage généré par G contient exactement les mots dérivables à partir de l'axiome et ne contenant que des symboles terminaux.

Définition (Grammaires équivalentes)

Deux grammaires G et G' sont dites équivalentes, noté $G \equiv G'$, si elles engendrent le même langage.

$$G \equiv G' \Leftrightarrow L(G) = L(G')$$

Les arbres de dérivation

Un arbre de dérivation est un outil qui permet de savoir si un mot w est généré par une grammaire G .

- L'arbre de dérivation est construit à partir de l'axiome. S'il atteint un état où toutes les feuilles de l'arbre sont terminales et correspondant à w alors w appartient à $L(G)$.
- L'arbre de dérivation permet aussi de retrouver intuitivement le langage généré par la grammaire en procédant par productions successives.

Exemple : Soit la grammaire $G=(T=\{a, b\}, N=\{S, A, B\}, S, P)$ où P est défini par :
 $P=\{S \rightarrow abS / A; A \rightarrow aAB / \varepsilon; B \rightarrow bbB / bb ; \}$

$W = abaabb$ n'est pas généré par la grammaire G .

Blocage pour B qui se ne réduit pas à ε (arbre page suivante à droite)



Exemple 2 :

Soit la grammaire $G = \langle T, N, S, P \rangle$ où

$T = \{+, -, /, *, (,), a\}$,

$N = \{S\}$, $P = \{S \rightarrow S+S; S \rightarrow S-S; S \rightarrow S*S; S \rightarrow S/S; S \rightarrow (S); S \rightarrow a\}$

Donnez un arbre de dérivation pour le mot $(a + a)/((a*a)-a)$



Classification de Chomsky

Noam Chomsky a défini quatre types de grammaires formelles suivant la nature des règles de production des grammaires.

Type 3 (Grammaires régulières)

Si toutes les productions dans P sont de la forme : $A \rightarrow wB$ ou $A \rightarrow w$ avec $A, B \in N$ et $w \in T^*$

Type 2 (Grammaires à contexte libre ou grammaire algébrique)

Si toutes les productions de P sont de la forme : $A \rightarrow \alpha$ avec $A \in N$ et $\alpha \in (T \cup N)^*$

Type 1 (Grammaires à contexte lié)

Si toutes les règles de production de P sont de la forme :

$\alpha A \beta \rightarrow \alpha w \beta$ avec $\alpha, \beta \in (T \cup N)^*$, $A \in N$, $w \in (T \cup N)^+$

seul l'axiome peut générer le mot vide ϵ et dans ce cas S n'apparaît pas en partie droite d'une autre règle.

Type 0 (Grammaire sans restriction) :

Si la forme des règles de production dans P n'est l'objet d'aucune restriction.

Hiérarchie de Chomsky (Classification des grammaires)

Il existe une relation d'inclusion entre ces quatre types de grammaires.

Autrement dit, on a

$$\text{type 3} \subseteq \text{type 2} \subseteq \text{type 1} \subseteq \text{type 0}.$$

(à une exception près que seul l'axiome peut générer epsilon dans le cas du type 1)

A chaque type de grammaire est associé un type de langage.

- Les grammaires de type 3 génèrent les langages **réguliers**.
- Les grammaires de type 2 génèrent les **langages algébriques ou à contexte libre**,
- Les grammaires de type 1 génèrent les langages **à contexte lié**.
- Les grammaires de type 0 permettent de générer tous les langages **décidables**. Autrement dit, tous les langages qui peuvent être reconnus en un temps fini par une machine.

Classification des langages

Définition (Type d'un langage)

Un langage est de type i s'il existe une grammaire de type i qui le génère. Un langage est strictement de type i s'il est engendré par une grammaire de type i et il n'existe pas de grammaire de type supérieur qui peut le générer.

Remarque : Un langage peut être généré par différentes grammaires qui peuvent être de types différents. Dans ce cas : Un langage prend le plus petit type au sens de l'inclusion.

Exemples classiques de langages

Type 3 $L = \{a^n b^m / n, m \geq 0\}$.

Une grammaire de type 3 qui engendre L est :

$G = (\{a, b\}, \{S, R\}, S, \{S \rightarrow aS / R / \varepsilon ; R \rightarrow bR / \varepsilon\})$.

Type 2 $L = \{a^n b^n / n \geq 0\}$ Une grammaire de type 2 qui engendre L est :

$G = (\{a, b\}, \{S\}, S, \{S \rightarrow aSb / \varepsilon\})$

Type 1 $L = \{a^n b^n c^n / n \geq 0\}$ Une grammaire de type 1 qui engendre L est :

$G = (\{a, b\}, \{S, R, T\}, S, P)$ où P est défini par

$S \rightarrow aRbc / abc / \varepsilon$

$R \rightarrow aRTb / aTb$

$Tb \rightarrow bT$

$Tc \rightarrow cc$

Classification des langages :

Tout langage est associé à un type d'automate qui permet de reconnaître les langages de sa classe :

- Les langages réguliers sont reconnus par des **automates d'états finis**
- Les langages algébriques sont reconnus par des **automates à piles**
- Les langages contextuels sont reconnus par des **automates à bornes linéaires**
- Les langages de type 0 sont reconnus par des **machines de Turing**.

Correspondance Grammaires/Langages/Automates

